

Efecto de la visibilidad de un agente virtual en el desempeño y la confianza del usuario en tareas de decisión basadas en reglas

Ney Fred Jiménez Campos (B03230)

Profesor: Dr. Alexander Barquero

Universidad de Costa Rica, Posgrado en Computación e Informática, PF-3311: Agentes Virtuales Inteligentes

Resumen: Pusimos a 15 adultos frente a escenarios ficticios de tránsito en tres rondas en la misma sesión: sin agente, chat con LLM y el mismo chat con avatar 3D que habla. El texto acertó más (81,1 % vs 55,6 % con avatar; $p = 0,022$) con el mismo modelo. La confianza no subió con el personaje; RAW-TLX se mantuvo; meCUE II valoró bien la estética del avatar. La calibración empeoró en C solo de forma descriptiva. Los bloques no compartían las mismas preguntas.

Palabras clave: agente virtual; confianza calibrada; diseño within-subjects; LLM; precisión; usabilidad

1. Introducción

Los tutores con LLM ya aparecen en cursos y simuladores de tránsito, casi siempre con cara y voz. Suena razonable, pero en tareas donde la respuesta está en una regla escrita no está claro que el encarnamiento ayude.

En este piloto within-subjects ($N = 15$) cada persona pasó por tres bloques: sin agente (A), chat con Gemini (B) y el mismo chat leído por un avatar 3D con voz Azure (C), sobre escenarios ficticios de reglas de tránsito. Preguntamos si cambiaba la precisión (RQ1), la confianza tras cada ítem (RQ2) y el ajuste entre confianza y aciertos (RQ3). Como marco exploratorio supusimos que la asistencia superaría a A y que el avatar subiría la confianza, aunque no necesariamente alineada con el rendimiento.

2. Trabajos relacionados

Los agentes encarnados pueden enganchar más (Cassell et al., 2000; Bickmore & Picard, 2005), pero el efecto depende de la tarea (Song et al., 2023).

Más cara o más voz no arreglan por sí solas la calibración entre confianza y desempeño (Kulms & Kopp, 2018; Moradinezhad & Solovey, 2021). Una interfaz que parece competente puede empujar a confiar de más (Lee & See, 2004; Luo et al., 2023).

Pocos trabajos fijan el contenido del LLM al comparar texto y avatar; aquí B y C comparten modelo y prompt.

3. Desarrollo del agente

Montamos un prototipo en Unity (Windows, 1920×1080) con Gemini 2.5 Flash, voz Azure (es-MX-JorgeNeural) y registro en CSV.

En A hay seis ítems sin chat. En B y C se puede consultar al agente entre preguntas; el prompt lo limita a orientar sin dar la letra. En C un avatar 3D (TTBoyB) lee en voz alta la misma respuesta textual que en B.

Unity guarda acierto, confianza (1 a 7) y tiempo por ítem; en B/C también el chat. Tras cada bloque pasamos RAW-TLX y meCUE 2.0 en Forms.

4. Método

Reclutamos adultos mayores de 18 años de forma abierta. 15 personas completaron los tres bloques (6+6+6 ítems).

En la muestra (Tabla 0, Fig. 0) hubo 15 adultos de reclutamiento abierto, con mayoría en el rango 25 a 34 años y estudios sobre todo universitarios o técnicos. 11 de 15 usaban asistentes digitales casi a diario; 13 ya habían probado avatares o agentes virtuales.

Cada participante recorrió A, B y C en orden contrabalanceado: sin agente; chat con Gemini; el mismo chat con avatar 3D y voz Azure. Las preguntas eran de opción múltiple sobre reglas de tránsito ficticias. Tras cada respuesta registramos confianza (1 a 7); al cierre de cada bloque, RAW-TLX y meCUE 2.0 en Forms.

Para RQ1 tomamos el % de aciertos por bloque en Unity; el contraste central es B frente a C, porque comparten LLM y prompt. RQ2 se apoya en esa confianza inmediata; RAW-TLX y meCUE (mód. I y III–V en B/C; mód. II de estética solo tras C) describen carga y experiencia. RQ3 es la brecha entre confianza normalizada y proporción de aciertos.

B y C usan el mismo system prompt, pero no las mismas preguntas: el diseño apunta a modalidad, no a dificultad idéntica ítem a ítem. El estudio corrió como aplicación de escritorio en Windows; en C las respuestas del LLM pasan por Azure Speech con lip-sync. También registramos intercambios de chat, HelpScore, latencia y filtraciones.

Las medias por condición se contrastaron con Friedman y Wilcoxon pareado (Bonferroni, $\alpha = 0,05$). Con $n = 15$ e ítems no equiparados, interpretamos con cautela.

Tabla 0. Perfil de participantes (resumen)

Edad	Educación	Asistentes
25 a 34 años	Universidad completa (grado / licenciatura)	Varias veces
18 a 24 años	Universidad incompleta	Algunas veces
25 a 34 años	Técnico / diplomado	Algunas veces
35 a 44 años	Técnico / diplomado	Casi todos los días

	45 a 54 años	Técnico / diplomado	Casi todos los días	0,0
	45 a 54 años	Primaria completa	Casi todos los días	1
	18 a 24 años	Universidad completa (grado / licenciatura)	Casi todos los días	15
	25 a 34 años	Posgrado (maestría / doctorado)	Casi todos los días	12
	25 a 34 años	Universidad completa (grado / licenciatura)	Algunas veces por semana	12
	25 a 34 años	Universidad completa (grado / licenciatura)	Casi todos los días	80,0
	25 a 34 años	Universidad completa (grado / licenciatura)	Casi todos los días	80,0
	35 a 44 años	Universidad completa (grado / licenciatura)	Varias veces al día	1
	35 a 44 años	Posgrado (maestría / doctorado)	Varias veces al día	1
	35 a 44 años	Posgrado (maestría / doctorado)	Casi todos los días	
	55 a 64 años	Primaria completa	Algunas veces por semana	
	25 a 34 años	Universidad completa (grado / licenciatura)	Casi todos los días	

5.1 Precisión y salvedad de ítems

El chat en texto fue el bloque más fuerte: 81,1 % de aciertos de media, frente a 55,6 % con avatar (A: 68,9 %; B: 81,1 %; C: 55,6 %). En la misma persona, 11 de 15 rindieron mejor en B que en C (Fig. 2). Wilcoxon B vs C: p = 0,022; IC 95 % de la diferencia [-38,9; -13,3] puntos porcentuales. Friedman global: p = 0,005, aunque los pares A vs B y A vs C no resistieron Holm.

Hay que leerlo con cuidado: cada bloque trajo preguntas distintas. Solo en la pregunta 4 el % de acierto se separó hasta 67 puntos entre bloques (Fig. 3). La Fig. 4 indica que el orden contrabalanceado no basta para explicar la ventaja de B. En la práctica vimos B > A > C, no la pareja B y C por encima de A que habíamos planteado al inicio.

Tabla I. Precisión media por condición (% aciertos)

	Media	N
	68,89	15
	81,11	15
	55,56	15

5. Resultados

15 personas cerraron los tres bloques (seis ítems por condición). Los registros no trajeron filas inválidas ni filtraciones de respuesta; en C la síntesis de voz funcionó en los casos en que se intentó.

Tabla V. Viabilidad técnica del estudio

	Valor
	270
	270
	100,0
	1
	1
	1
	0




Fig. 0. Perfil de la muestra





Fig. 1. Precisión media por condición

RQ1 — Misma persona: precisión en B vs C



Cada línea une a un participante (n=15). B > C: 11; C > B: 1; empate: 3.

Fig. 2. Precisión B vs C por participante (within-subjects)




Fig. 3. Precisión por ítem y condición (ítems distintos por bloque)



Fig. 4. Precisión media según posición del bloque en la sesión

5.2 Confianza y cuestionarios

Tras cada ítem la confianza (Tabla II, Fig. 5) se quedó alta en las tres condiciones (A 6,52, B 6,50, C 6,20 sobre 7) y no subió con el avatar. Friedman: $p = 0,024$; el par A vs C

fue el más llamativo ($p = 0,033$ tras Holm), pero sin el salto que esperábamos al ver el personaje.

RAW-TLX (Tabla VI, Fig. 6) apenas se movió entre A, B y C (4,3, 4,3 y 4,3 sobre 7): pasar por el avatar no dejó la tarea más pesada en papel.

En meCUE (Tabla VII, Fig. 7) la utilidad del agente fue un poco mayor en C (5,989 vs 5,6 en mód. I), con p crudo 0,028 que Holm no confirma. El resto de subescalas B vs C se parecen.

meCUE II (Tabla VIII), solo tras C, dejó 5,63/7 en estética del avatar: el personaje gustó aunque ese bloque fue el peor en aciertos.

Tabla II. Confianza media por condición (Unity, escala de 1 a 7)

	Media	N
	6,522	15
	6,5	15
	6,2	15




Fig. 5. Confianza media por condición

Tabla VI. RAW-TLX por condición

	Media	N
	4,322	15
	4,289	15
	4,267	15




Fig. 6. Carga de trabajo (RAW-TLX) por condición

Tabla VII. meCUE: medias B vs C (mód. I)

	Media B	Media C	N B	N C
	5,6	5,989	15	15
	4,622	4,811	15	15
	4,767	5,1	15	15
	3,133	3,267	15	15




Fig. 7. meCUE: comparación B vs C

Tabla VIII. meCUE Módulo II (estética del avatar, solo C)

	Media C	N
	5,627	15

5.3 Calibración y tiempo

La brecha entre confianza y aciertos (Tabla III, Fig. 8) fue mayor en C (0,311) que en B (0,106) o A (0,232), aunque Friedman no la declaró significativa ($p = 0,21$). Por ítem (Fig. 9) el desajuste en C se nota sobre todo en Q4 a Q6, donde varios marcaron confianza alta y fallaron. C fue también el bloque más lento (~56 % más que A por ítem; 177 s vs 114 s; Fig. 10).

Tabla III. Brecha de calibración por condición

	Brecha	N
--	--------	---

	0,2315	15			
	0,1056	15		55,0	63,343
	0,3111	15		41,875	58,414
				3,625	4,429
				0,0	0,0
				135,965	153,437
				95,963	84,444
				2,0	2,0




Fig. 8. Brecha de calibración




Fig. 9. Brecha de calibración por ítem




Fig. 10. Tiempo medio por ítem (segundos)

5.4 Agente conversacional

El agente debía orientar sin dar la letra. Doce de quince sesiones con chat alcanzaron al menos un intercambio por bloque.

En C hubo más turnos (4,4 frente a 3,6 en B; Fig. 11) y más preguntas sustantivas (2,0 vs 2,0 en promedio) y el modelo no filtró respuestas (Fig. 13), pero los aciertos cayeron. Hablar más con el tutor no compensó.

Tabla IV. Métricas del agente (B vs C)

	Media B	Media C
--	---------	---------




Fig. 11. Intercambios de chat por bloque (B vs C)




Fig. 12. HelpScore B vs C



Fig. 13. Leaks del modelo (B vs C)

5.5 Caso ilustrativo

P04 pasó de 83 % en B a 17 % en C con el mismo LLM. Cinco personas hicieron el camino opuesto ($C > B$); el ejemplo ayuda a ver el within-subjects sin quedarnos con un solo relato.

6. Discusión

Moradinezhad y Solovey (2021) ya mostraron que un cuerpo en pantalla no obliga a decidir mejor. Aquí pasó algo parecido: mismo Gemini, peor rendimiento cuando la respuesta llegó con voz y avatar.

Los números de aciertos y tiempo cuentan una historia distinta a los cuestionarios. C perdió frente a B con el mismo LLM y tardó más por ítem; la brecha entre confianza y aciertos también fue más amplia con avatar, aunque sin significancia global (ver resultados). Eso apunta más a un coste de la modalidad que a un tutor peor en fondo.

En lo subjetivo, meCUE II dejó 5,63/7 en estética. RAW-TLX y el resto de meCUE tampoco pintaron C como una experiencia claramente peor. Se puede disfrutar el personaje y aun así fallar más: si lo que importa es aprender en el acto, el texto ganó; si se quiere conservar el avatar, habría que aligerar voz y esperas.

Al cerrar dejaron comentarios anónimos que encajan con lo anterior. A uno la voz del avatar le sacaba concentración; a otro le faltó poder hablarle por micrófono (solo había TTS). Alguien intentó que el agente revelara la respuesta y no pudo; los logs no muestran filtraciones.

También surgió que C se sintió más incómodo y las preguntas «un poco más duras», cosa a recordar porque B y C no compartían ítems. Entre personas la dificultad del material varió mucho (16 % a 100 % de aciertos), algo esperable con edades y estudios mezclados.

Con 15 personas, ítems distintos por bloque y escenarios inventados, esto orienta el prototipo más que generalizar a otro dominio sin repetir el estudio.

El estudio se ejecutó en las computadoras personales de los participantes mediante un ejecutable local, no en la máquina virtual en la nube prevista al inicio; por eso el entorno (hardware y, en C, la latencia de voz y el render del avatar) no fue uniforme entre participantes.

7. Conclusiones

Con el mismo Gemini y el mismo prompt, el chat en texto fue más preciso que la misma ayuda con avatar y voz. En reglas explícitas el encarnamiento no mejoró aciertos ni confianza de inmediato.

La confianza se quedó alta en todas las condiciones ($C = 6,20/7$); si repetimos el estudio, valdría la pena revisar si la escala 1 a 7 discrimina lo bastante.

El registro automático y el diseño within-subjects funcionaron sin problema. Antes de escalar faltaría

equiparar ítems, subir N y probar C sin voz o con micrófono abierto.

Referencias

- [1] Bickmore, T. W., & Picard, R. W. (2005). Establishing and maintaining long-term human-computer relationships. *ACM Transactions on Computer-Human Interaction*, 12(2), 293–327.
- [2] Cassell, J., Sullivan, J., Prevost, S., & Churchill, E. (Eds.). (2000). *Embodied conversational agents*. MIT Press.
- [3] Kulms, P., & Kopp, S. (2018). A social cognition perspective on human–computer trust. *Frontiers in Digital Humanities*, 5, 14.
- [4] Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. *Human Factors*, 46(1), 50–80.
- [5] Luo, L., Weng, D., Ding, N., Hao, J., & Tu, Z. (2023). The effect of avatar facial expressions on trust building in social virtual reality. *The Visual Computer*, 39(11), 5869–5882.
- [6] Minge, M., & Thüning, M. (2018). *meCUE 2.0*. *Proceedings of Mensch und Computer 2018*.
- [7] Moradinezhad, R., & Solovey, E. T. (2021). Investigating trust in interaction with inconsistent embodied virtual agents. *Proceedings of the 26th International Conference on Intelligent User Interfaces*, 327–337.
- [8] Song, Y., Luximon, A., & Luximon, Y. (2023). Psychological insights into embodied conversational agents, chatbots and social assistive robots: A systematic meta-review. *Behaviour & Information Technology*.
- [9] Yee, N., & Bailenson, J. (2007). The Proteus effect. *Communication Research*, 34(3), 271–290.