

Universidad de Costa Rica

PROGRAMA DE POSGRADO EN COMPUTACIÓN E INFORMÁTICA

PF-3311 – Agentes Virtuales Inteligentes

ENTREGABLE 3

Resultados de Agente e Investigación

***Efecto de la visibilidad de un agente virtual en el desempeño y la confianza del usuario
en tareas de decisión basadas en reglas***

Profesor

Dr. Alexander Barquero

Investigador Principal:

Ney Fred Jiménez Campos

Fecha

22 de junio 2026

I Ciclo, 2026

Índice

1. Resumen y guía de términos
 2. Muestra, flujo y metodología
 3. RQ1: Precisión
 4. RQ2: Confianza
 5. RQ3: Calibración
 6. Cuestionarios (RAW-TLX / meCUE) y tiempo
 7. Agente (B vs C)
 8. Viabilidad técnica
 9. Limitaciones del diseño
 10. Respuestas a las preguntas de investigación
 - 10,1 Funcional vs perceptual
 - 10,2 Comentarios de participantes
 - 10,3 Implicaciones para diseño
 11. Discusión
 12. Conclusiones
- Referencias
- Anexo A: Métricas, fórmulas y origen de datos
- Anexo B: Inferencia estadística

1. Resumen

Quince participantes completaron el estudio PF-3311: cada persona pasó por A (sin agente), B (chat con Gemini) y C (mismo chat con avatar y voz), con seis ítems por bloque sobre reglas de tránsito. El problema que guía el trabajo es: Efecto de la visibilidad de un agente virtual en el desempeño y la confianza del usuario en tareas de decisión basadas en reglas.

Cada condición usó preguntas distintas; por eso el contraste más fiable es B vs C (mismo modelo de lenguaje, distinta presentación). Esa salvedad se desarrolla al inicio de la sección 3.

En precisión, el orden fue B (81,1 %) > A (68,9 %) > C (55,6 %); B superó a C en 11 de 15 participantes (Wilcoxon $p \approx 0,022$). En confianza, C quedó última (6,20/7), no primera: el avatar no aumentó la sensación de seguridad.

La brecha entre confianza y aciertos fue algo mayor en C (0,311) que en B (0,106); H3 tiene apoyo descriptivo, sin prueba inferencial fuerte.

Tras la sesión hubo comentarios dispersos: la voz del avatar desconcentraba a algunos; otro habría preferido hablarle al agente por voz en lugar de solo chat escrito y escucharlo; otros valoraron que el agente no diera la respuesta aunque insistieran. Sobre la dificultad, hubo quien calificó el material como muy exigente y quien lo vio sencillo, coherente con una muestra de perfiles distintos (sección 2).

El registro CSV fue íntegro (100,0 % de filas válidas, 0 leaks). El detalle por RQ, tablas y figuras está en las secciones 3 a 7; fórmulas e inferencia, en los anexos.

Guía rápida de términos

A / B / C: sin agente, chat de texto, avatar con voz.

Precisión: % de respuestas correctas en el bloque (6 preguntas).

Confianza: qué tan seguro se sintió el participante (1 = nada, 7 = mucho).

Brecha de calibración: desajuste entre confianza y aciertos; positivo $\approx$ más confianza que aciertos.

HelpScore: utilidad pedagógica del chat (evaluación automática).

RAW-TLX: carga de trabajo percibida tras cada bloque (más alto = más exigente).

meCUE: experiencia con el agente conversacional (bloques B y C); Mód. II solo en C.

Tiempo de respuesta: segundos entre ver la pregunta y pulsar entregar (Unity).

Las definiciones completas (fórmulas, origen CSV, pruebas estadísticas) están en el Anexo A.

2. Muestra, flujo y metodología

Se registraron 16 sesiones en el estudio.

Para el análisis se utilizó una sesión canónica por participante (n=15).

Compleitud A+B+C: 15/15 participantes (100,0%).

Criterios de inclusión y flujo de datos para el análisis cuantitativo.

Se registraron 16 sesión(es) en el sistema. De esas, 15 se tomaron como canónicas (una por participante P##, sin duplicados).

1 sesión(es) quedaron fuera por repetición o sesiones incompletas.

15 de 15 participantes canónicos completaron A, B y C con 6 ítems cada uno (100,0 %). La meta de completitud del diseño era ≥ 80 %.

La Tabla F resume el embudo; la Tabla S detalla ítems y consentimiento por persona. Las medias, gráficos e inferencia usan por defecto solo quienes cerraron los tres bloques.

Tabla F. Embudo de participantes

Etapas	N	Nota
Sesiones registradas	16	Total detectado
Sesiones canónicas (análisis)	15	Una por P##
Con consentimiento registrado	15	HasConsent = 1
Completas A+B+C (6+6+6 ítems)	15	Subconjunto principal de inferencia

Tabla S. Detalle por participante canónico

P##	Ítems A	Ítems B	Ítems C	Completa	Consent.
P01	6	6	6	Sí	Sí
P02	6	6	6	Sí	Sí
P03	6	6	6	Sí	Sí
P04	6	6	6	Sí	Sí

P##	Ítems A	Ítems B	Ítems C	Completa	Consent.
P05	6	6	6	Sí	Sí
P06	6	6	6	Sí	Sí
P08	6	6	6	Sí	Sí
P10	6	6	6	Sí	Sí
P11	6	6	6	Sí	Sí
P12	6	6	6	Sí	Sí
P13	6	6	6	Sí	Sí
P14	6	6	6	Sí	Sí
P15	6	6	6	Sí	Sí
P16	6	6	6	Sí	Sí
P17	6	6	6	Sí	Sí

Cada persona vivió las tres condiciones en la misma sesión: primero resolvió ítems sin ayuda (A), luego con chat de Gemini (B) y por último con el mismo chat presentado por un avatar 3D y voz Azure (C). Había seis preguntas distintas por bloque, con escenarios ficticios de reglas de tránsito; el orden de los bloques se contrabalanceó según el código P## en la aplicación.

Unity registró acierto, confianza (1 a 7) y tiempo por ítem. Tras cada bloque, Google Forms recogió RAW-TLX y meCUE 2.0; en B y C además se guardaron intercambios de chat, HelpScore y filtraciones del modelo.

El Módulo I de meCUE evalúa la usabilidad del asistente, con ítems de facilidad de uso («es fácil de usar», «es evidente cómo usarlo», «los procedimientos son sencillos de entender»). Esos ítems cubren el constructo del SUS abreviado previsto en el Entregable 2, por lo que la usabilidad se midió con meCUE y no se aplicó un SUS por separado.

Para el análisis se conservó una sesión canónica por participante. El subconjunto principal son quienes cerraron A, B y C con seis ítems cada uno: $n = 15$ de 15.

Los resultados se resumen con medias por condición y se contrastan con Friedman, Wilcoxon pareado (Bonferroni y Holm), bootstrap al 95 % y contrastes dirigidos (H3 C vs A, precisión B vs C, HelpScore). Las fórmulas están en el Anexo A.

La muestra es pequeña ($n = 15$) pero suficiente para explorar el diseño. Hay además comentarios breves post-sesión (sección 10,2) y revisión de protocolo con expertos.

Al inicio de la sesión cada participante completó el Formulario de Perfil del Participante en Google Forms (15 registros en el estudio).

Rango de edad: 25 a 34 años (n=6, 40%); 35 a 44 años (n=4, 27%); 18 a 24 años (n=2, 13%); 45 a 54 años (n=2, 13%); 55 a 64 años (n=1, 7%).

Nivel educativo: Universidad completa (grado / licenciatura) (n=6, 40%); Posgrado (maestría / doctorado) (n=3, 20%); Técnico / diplomado (n=3, 20%); Primaria completa (n=2, 13%); Universidad incompleta (n=1, 7%).

Uso de asistentes digitales: Casi todos los días (n=8, 53%); Algunas veces por semana (n=4, 27%); Varias veces al día (n=3, 20%).

Experiencia con avatares/agentes: Algunas veces (n=10, 67%); Con frecuencia (n=2, 13%); Nunca (n=2, 13%); Una o pocas veces (n=1, 7%).

Participantes con experiencia previa en avatares/agentes (≠ «Nunca»): 13/15 (87%).

Uso frecuente de asistentes digitales (diario o casi diario): 11/15 (73%).

Estas variables no entran en Friedman ni Wilcoxon; solo describen quién participó. La mezcla de edades y escolaridad ayuda a entender por qué unos encontraron los ítems muy duros y otros, fáciles: sin público objetivo claro, calibrar preguntas es complicado.

Tabla P. Perfil de participantes (Formulario de Perfil del Participante)

P##	Edad	Educación	Asistentes digitales	Avatares/agentes
P01	25 a 34 años	Universidad completa (grado / licenciatura)	Varias veces al día	Algunas veces
P02	18 a 24 años	Universidad incompleta	Algunas veces por semana	Una o pocas veces
P03	25 a 34 años	Técnico diplomado /	Algunas veces por semana	Algunas veces
P04	35 a 44 años	Técnico diplomado /	Casi todos los días	Algunas veces
P05	45 a 54 años	Técnico diplomado /	Casi todos los días	Con frecuencia
P06	45 a 54 años	Primaria completa	Casi todos los días	Algunas veces
P08	18 a 24 años	Universidad completa (grado / licenciatura)	Casi todos los días	Algunas veces

P##	Edad	Educación	Asistentes digitales	Avatares/agentes
P10	25 a 34 años	Posgrado (maestría / doctorado)	Casi todos los días	Con frecuencia
P11	25 a 34 años	Universidad completa (grado / licenciatura)	Algunas veces por semana	Algunas veces
P12	25 a 34 años	Universidad completa (grado / licenciatura)	Casi todos los días	Nunca
P13	35 a 44 años	Universidad completa (grado / licenciatura)	Varias veces al día	Algunas veces
P14	35 a 44 años	Posgrado (maestría / doctorado)	Varias veces al día	Algunas veces
P15	35 a 44 años	Posgrado (maestría / doctorado)	Casi todos los días	Algunas veces
P16	55 a 64 años	Primaria completa	Algunas veces por semana	Nunca
P17	25 a 34 años	Universidad completa (grado / licenciatura)	Casi todos los días	Algunas veces




Figura 1. Perfil de la muestra (Formulario de Perfil del Participante)

Nota sobre la figura

Caracteriza quiénes participaron (Formulario de Perfil del Participante). No responde RQ1 a RQ3; permite saber si la muestra era familiar con asistentes digitales o avatares antes del experimento. Varios paneles (barras o torta) con frecuencias de edad, educación, uso de asistentes y experiencia con avatares. Cada segmento = cuántos participantes eligieron esa opción (total N = 15). Unidad: conteo y porcentaje de personas (no hay escala 1 a 7). Origen: Google Forms (Formulario de Perfil del Participante) antes de la sesión Unity. No proviene del simulador ni del chat.

Identifique la categoría más frecuente en cada panel. No compare A/B/C (esta figura es previa al experimento). Un 60 % en un rango de edad = 9 de 15 personas.

Edad más frecuente: «25 a 34 años» (6/15 = 40 %). 11/15 usan asistentes casi a diario; 2/15 nunca habían usado avatares.

Contexto demográfico para generalizar con cautela (N = 15, reclutamiento por conveniencia). No explica por sí sola por qué B > C en precisión.

Casos ilustrativos

Dos recorridos individuales (P01 y P03) ilustran el intrasujeto.

A modo de ejemplo, P01 recorrió el estudio en orden A → B → C. Sin agente (A) acertó 83,3 % con confianza 5,00 (brecha -0,167). Con chat (B) bajó a 66,7 % con confianza 5,33 En B usó el chat con HelpScore 72,5/100 y 3 preguntas sustantivas al agente. Con avatar (C) repitió 66,7 % de aciertos, confianza 5,00 y brecha 0,000.

Tras C, en meCUE II (estética del avatar) puntuó 5,8/7: la presencia del personaje fue bien recibida aunque no se tradujo en más aciertos ni más confianza en ese bloque.

A modo de ejemplo, P03 recorrió el estudio en orden C → B → A. Sin agente (A) acertó 66,7 % con confianza 7,00 (brecha 0,333). Con chat (B) bajó a 83,3 % con confianza 7,00 Con avatar (C) repitió 16,7 % de aciertos, confianza 6,83 y brecha 0,806.

Tras C, en meCUE II (estética del avatar) puntuó 6,8/7: la presencia del personaje fue bien recibida aunque no se tradujo en más aciertos ni más confianza en ese bloque.

No reemplazan el análisis grupal, pero muestran que la misma persona rinde distinto según la modalidad.




Figura 2. Precisión por ítem y condición (salvedad metodológica)

Nota sobre la figura

Salvedad metodológica: cada condición (A, B, C) usó seis preguntas distintas. Esta figura muestra si la dificultad fue pareja o si algún bloque traía ítems mucho más fáciles o difíciles, lo cual afecta la lectura de RQ1. Barras de % de aciertos por ítem (Q1 a Q6) en A, B y C. Cada barra = proporción de aciertos del grupo (N = 15) en esa pregunta concreta. Unidad: porcentaje 0 a 100 % por ítem y condición. Origen: aciertos registrados en la aplicación Unity. No es el promedio del bloque (véase Figura 4).

Compare la altura de Q1 a Q6 entre colores. Si B domina porque sus ítems son más fáciles (p. ej. Q4), parte del efecto B > C puede ser de contenido, no solo de modalidad.

A (sin agente): % medio por ítem $\approx 68,9$ % (Q1 a Q6). B (chat texto): % medio por ítem $\approx 81,1$ % (Q1 a Q6). C (avatar y voz): % medio por ítem $\approx 55,6$ % (Q1 a Q6). El ítem con mayor contraste entre condiciones es Q4 (hasta ~ 67 pp entre A, B y C).

Refuerza usar B vs C (mismo modelo de lenguaje) como contraste principal y no sobreinterpretar A vs B vs C en bloque. Complementa Figura 3 (orden/fatiga).




Figura 3. Precisión media según posición del bloque en la sesión

Nota sobre la figura

Descarta que los resultados se deban solo a orden de bloques o fatiga: ¿mejoró o empeoró el rendimiento según si A/B/C fue el 1.º, 2.º o 3.º bloque?. Barras con precisión media según la posición del bloque en la sesión (1 = primer bloque del participante, 2 = segundo, 3 = tercero), promediando todas las condiciones que ocuparon esa posición. Unidad: % aciertos medio del bloque. Cálculo: se agrupa por posición 1 a 3 en la secuencia individual (contrabalanceo por código P##), no por letra A/B/C. N = 15 bloques por posición.

Si la posición 3 fuera mucho peor que la 1, podría haber fatiga; si la 3 fuera mejor, aprendizaje intra-sesión. Patrón plano = el orden por sí solo no explica $B > C$.

Posición 1ª del bloque en la sesión: 67,8 % aciertos medios. Posición 2ª del bloque en la sesión: 65,6 % aciertos medios. Posición 3ª del bloque en la sesión: 72,2 % aciertos medios.

En este estudio las medias por posición fueron parecidas (~66 a 72 %), sin tendencia fuerte de fatiga o práctica. No elimina la salvedad de ítems distintos (Figura 2).

3. RQ1: Precisión

Cada figura del informe incluye una nota de lectura (unidades, cálculo y contexto) junto al gráfico.

Salvedad metodológica: cada bloque (A, B, C) usó seis preguntas distintas sobre reglas de tránsito. Las barras y medias por condición mezclan, por tanto, dificultad del ítem y tipo de asistencia. En la pregunta 4, por ejemplo, el % de acierto varió hasta 67 puntos entre condiciones. Por eso el informe enfatiza B vs C: mismo modelo de lenguaje y mismo participante, aunque los ítems del bloque B y del C también difieren entre sí.

La Figura 2 documenta el balance por ítem; la Figura 5 muestra el contraste B vs C persona a persona.

RQ1 pregunta si cambia el porcentaje de aciertos entre A (sin agente), B (chat) y C (avatar).

B obtuvo los mejores aciertos y C los más bajos. El resultado más firme es que B superó a C en la misma persona: el modelo es el mismo y solo cambia cómo se presenta la ayuda (texto frente a avatar con voz).

La Tabla 1 trae la precisión media del grupo en cada bloque de seis preguntas.

A (sin agente): media 68,89 % (n=15 participantes).

B (chat texto): media 81,11 % (n=15 participantes).

C (avatar y voz): media 55,56 % (n=15 participantes).

El contraste pareado B vs C mostró $\Delta = -25,6$ pp (IC 95 % bootstrap [-38,9; -13,3]).

Friedman ($p \approx 0,005$) indica que las tres condiciones no son equivalentes en conjunto; el único contraste pareado significativo tras corrección es $B > C$ ($p \approx 0,022$).

Dentro de cada participante (B vs C): 11 con $B > C$, 1 con $C > B$, 3 empates.

Tabla 1. Precisión por condición (% aciertos)

Condición	Media %	N
A	68,89	15
B	81,11	15
C	55,56	15

Fuente: registro automático de la aplicación Unity (respuesta y corrección por ítem). **Fórmula por participante y bloque:** $\text{Precisión} = (\text{aciertos} \div 6) \times 100$. **Fórmula de la tabla:** media aritmética de esos % entre los N = 15 completos. **Por qué:** mide desempeño objetivo (RQ1); % facilita comparar bloques.

Descriptivos de precisión

Cond.	Métrica	N	Media	Mediana	DE	Mín.	Máx.
A	Precisión (0 a 1)	15	0,69	0,67	0,26	0,17	1,00
B	Precisión (0 a 1)	15	0,81	0,83	0,14	0,67	1,00
C	Precisión (0 a 1)	15	0,56	0,67	0,30	0,00	1,00

Cómo leer: cada fila es una condición (A, B, C). Media = promedio del grupo; Mediana = valor central; DE = desviación estándar (qué tan dispersos están los datos); Mín. y Máx. = valores más bajo y más alto entre los 15 participantes.

Precisión por participante

Participante	A %	B %	C %
P01	83,33	66,67	66,67
P02	83,33	66,67	66,67
P03	66,67	83,33	16,67
P04	66,67	83,33	16,67
P05	50,00	66,67	0,00
P06	66,67	66,67	16,67
P08	83,33	100,00	83,33
P10	33,33	83,33	66,67
P11	100,00	100,00	100,00
P12	83,33	100,00	66,67
P13	100,00	66,67	83,33
P14	33,33	83,33	66,67
P15	100,00	100,00	83,33
P16	66,67	83,33	50,00

Participante	A %	B %	C %
P17	16,67	66,67	50,00

Cada fila es un participante (P01–P17, sin P07 ni P09). A %, B %, C % = su porcentaje de aciertos en el bloque de 6 preguntas de cada condición.




Figura 4. Precisión media por condición

Nota sobre la figura

Responde RQ1: ¿en qué condición acertaron más? Mide el desempeño objetivo (aciertos en reglas de tránsito), no la opinión del participante. Tres barras: A (sin agente), B (chat texto), C (avatar + voz). La altura de cada barra es el promedio del grupo en esa condición. Unidad: porcentaje (0 a 100 %). Origen: Unity registra si cada respuesta fue correcta; por participante se calcula (aciertos ÷ 6 ítems del bloque) × 100. La barra es la media aritmética de esos porcentajes individuales (N = 15).

Compare alturas. +10 pp ≈ una pregunta más acertada de media en el bloque. Distancias grandes = diferencias marcadas entre grupos; no sustituye ver cada persona en la Figura 5.

Medias grupales (N = 15): A = 68,9 %, B = 81,1 %, C = 55,6 %. Cada % es el promedio del «% de aciertos en el bloque» de cada participante (0 % = 0/6 correctas; 100 % = 6/6). Ej.: B = 81,1 % equivale en promedio a ≈ 4,9 de 6 ítems acertadas por persona. Orden observado: B > A > C (H1 esperaba C ≈ B > A). B superó a C en 25,5 puntos porcentuales (pp) en media grupal. El contraste pareado B vs C mostró $\Delta = -25,6$ pp (IC 95 % bootstrap [-38,9; -13,3]).

B y C comparten el mismo modelo de lenguaje; si la presentación no importara, B y C serían similares. La brecha B vs C apunta a la modalidad. Cada bloque tuvo ítems distintos; complemente con la Figura 5.

Tabla 1b. Precisión B vs C por participante ($\Delta = B - C$)

Código	B %	C %	Δ pp	Resultado
P05	66,67	0,00	66,67	B>C
P03	83,33	16,67	66,66	B>C
P04	83,33	16,67	66,66	B>C
P06	66,67	16,67	50,00	B>C
P12	100,00	66,67	33,33	B>C
P16	83,33	50,00	33,33	B>C
P08	100,00	83,33	16,67	B>C
P15	100,00	83,33	16,67	B>C
P17	66,67	50,00	16,67	B>C
P10	83,33	66,67	16,66	B>C
P14	83,33	66,67	16,66	B>C
P01	66,67	66,67	0,00	Empate
P02	66,67	66,67	0,00	Empate
P11	100,00	100,00	0,00	Empate
P13	66,67	83,33	-16,66	C>B

Fuente: mismo registro Unity, contraste pareado B vs C. **Fórmula:** $\Delta = \text{Precisión}_B - \text{Precisión}_C$ (puntos porcentuales, misma persona). **Por qué:** contraste intrasujeto con el mismo modelo de lenguaje; aísla modalidad.




Figura 5. Misma persona: precisión en chat texto (B) vs avatar y voz (C)

Nota sobre la figura

Profundiza RQ1 en B vs C (mismo tutor de IA). Pregunta si B > C es un promedio de grupo o un patrón intrasujeto (cada persona vive B y C). Dos columnas (B izquierda, C derecha); eje Y = % aciertos (misma escala que la Figura 4). Cada línea delgada = un participante (su % en B unido a su % en C). La línea negra gruesa = media del grupo. Unidad: porcentaje 0 a 100 % por persona y condición, calculado igual que en la Fig. 2 (aciertos $\div$ 6 $\times$ 100). Cada participante aporta un par (B, C); hay 15 pares completos en el estudio.

Siga una línea delgada: si baja hacia C, esa persona rindió peor con avatar; si sube, mejor en C; horizontal = mismo % en ambas. La negra resume la tendencia.

11/15 personas con B > C; 1 (P13) con C > B; 3 empates exactos. La mayoría de líneas bajan hacia C: el chat texto ganó persona por persona, no solo en promedio grupal.

El efecto B > C es consistente, no un outlier. Refuerza el contraste más interpretable del estudio, sin eliminar la salvedad de ítems distintos por bloque.

4. RQ2: Confianza

RQ2 pregunta si cambia la confianza (1 a 7) que cada persona marcó en Unity tras cada respuesta.

La confianza fue alta en las tres condiciones; C fue la más baja, no la más alta, el avatar no aumentó la sensación de seguridad.

La Tabla 2 trae las medias por condición.

A (sin agente): media 6,522 (n=15).

B (chat texto): media 6,5 (n=15).

C (avatar y voz): media 6,2 (n=15).

Friedman ($p \approx 0,024$) detectó diferencias globales; el par $A > C$ fue significativo ($p \approx 0,033$). B y C no difieren de forma robusta entre sí.

Tabla 2. Confianza media (Unity, escala de 1 a 7)

Condición	Media	N
A	6,522	15
B	6,5	15
C	6,2	15

Descriptivos de confianza

Cond.	Métrica	N	Media	Mediana	DE	Mín.	Máx.
A	Confianza (1 a 7)	15	6,52	7,00	0,69	5,00	7,00
B	Confianza (1 a 7)	15	6,50	7,00	0,69	5,33	7,00
C	Confianza (1 a 7)	15	6,20	6,50	0,99	3,67	7,00

Cómo leer: cada fila es una condición (A, B, C). Media = promedio del grupo; Mediana = valor central; DE = desviación estándar (qué tan dispersos están los datos); Mín. y Máx. = valores más bajo y más alto entre los 15 participantes.




Figura 6. Confianza media por condición

Nota sobre la figura

Responde RQ2: ¿la presencia del agente (y del avatar) cambia cuán seguro se siente el participante al responder? Mide confianza subjetiva inmediata, no aciertos (véase RQ1) ni calibración (RQ3). Tres barras con la confianza media del grupo en cada condición A, B y C. Escala: 1 a 7 (estrellas en Unity tras cada respuesta; 1 = nada seguro, 7 = muy seguro). Cálculo: por participante, promedio de las 6 calificaciones del bloque; la barra es la media de esos promedios individuales (N = 15). Un 6,5/7 ≈ marcar casi siempre 6 o 7 estrellas.

Valores cerca de 7 = techo de la escala (poco margen para «subir»). Compare si C (avatar) supera a B y A, como plantea H2 ($C > B > A$).

Medias: A (sin agente): 6,52/7; B (chat texto): 6,50/7; C (avatar y voz): 6,20/7. Orden observado: $A < B < C$ (coincide con H2). H2 no confirmada (C fue la más baja, no la más alta).

El avatar no aumentó la confianza. Las medias están cerca del techo, lo que dificulta detectar mejoras. Cruce con Figura 4 (aciertos) y Figura 10 (calibración). Complemento post-bloque: Figuras 7 a 8.

5. RQ3: Calibración

RQ3 pregunta si la confianza declarada «calza» con los aciertos reales (calibración).

B fue la condición más alineada; C mostró la mayor brecha descriptiva (más confianza que aciertos), pero sin significación estadística fuerte.

La brecha = confianza normalizada $((\text{valor}-1)/6)$ menos proporción de aciertos del bloque. La Tabla 3 muestra la media por condición.

A (sin agente): brecha media 0,2315 (n=15).

B (chat texto): brecha media 0,1056 (n=15).

C (avatar y voz): brecha media 0,3111 (n=15).

Tabla 3. Brecha de calibración por condición

Condición	Brecha media	N
A	0,2315	15
B	0,1056	15
C	0,3111	15

Fuente: confianza y aciertos por bloque en Unity. **Fórmula por bloque:** Brecha = $\text{media}((C-1)/6) - (\text{aciertos}/6)$, con C = confianza 1 a 7. **Tabla:** media de brechas individuales. **Por qué:** alinea sensación vs acierto (RQ3).

Descriptivos de brecha de calibración

Cond.	Métrica	N	Media	Mediana	DE	Mín.	Máx.
A	Brecha de calibración	15	0,23	0,17	0,30	-0,17	0,83
B	Brecha de calibración	15	0,11	0,17	0,19	-0,25	0,33
C	Brecha de calibración	15	0,31	0,33	0,39	-0,39	1,00

Cómo leer: cada fila es una condición (A, B, C). Media = promedio del grupo; Mediana = valor central; DE = desviación estándar (qué tan dispersos están los datos); Mín. y Máx. = valores más bajo y más alto entre los 15 participantes.

RQ3 — Brecha de calibración




Figura 10. Brecha de calibración por condición

Nota sobre la figura

Responde RQ3: ¿la confianza que reportan coincide con cuánto acertaron? Detecta sobreconfianza (sentirse seguro pese a fallar) o subconfianza. Tres barras con la brecha media de calibración del grupo en A, B y C. Unidad: diferencia adimensional (típicamente entre -1 y $+1$). Fórmula por bloque: (confianza media normalizada) $-$ (proporción de aciertos), donde la confianza se normaliza como (estrellas $- 1$) $\div 6$ (escala 1 a 7 $\rightarrow$ 0 a 1). Ejemplo: brecha $+0,31 \approx$ declarar ~ 31 pp más «seguridad normalizada» de la que los aciertos respaldan. Cálculo de la barra: media de las brechas individuales ($N = 15$).

Brecha ≈ 0 : alineación. Positiva: sobreconfianza media. Negativa: acertaron más de lo que dijeron sentir. $|brecha| > 0,05$ ya es desajuste notable.

A (sin agente): 0,232 (sobreconfianza (más confianza que aciertos)); B (chat texto): 0,106 (sobreconfianza (más confianza que aciertos)); C (avatar y voz): 0,311 (sobreconfianza (más confianza que aciertos)) C tuvo la brecha más alta (apoyo débil a H3; Friedman no significativo). Las cifras son promedios del bloque completo (6 ítems), no de una sola pregunta.

B fue la más calibrada; C la más desalineada en promedio. Detalle por pregunta: Figuras 11 a 12.

Además del promedio del bloque (Figura 10), el análisis desglosa la calibración pregunta por pregunta (Q1 a Q6). La Tabla 3b y las Figuras 11 a 12 permiten ver si el desajuste entre confianza y aciertos se concentra en ítems concretos del escenario.

Tabla 3b. Calibración por ítem (Q1 a Q6)

Condición	Ítem	N	Conf. norm.	% aciertos	Brecha
A	1	15	1,0	80,0	0,2
A	2	15	0,9444	73,33	0,2111
A	3	15	0,9	66,67	0,2333
A	4	15	0,9222	26,67	0,6556
A	5	15	0,9444	73,33	0,2111
A	6	15	0,8111	93,33	-0,1222
B	1	15	0,9778	100,0	-0,0222
B	2	15	0,7889	66,67	0,1222
B	3	15	0,9111	73,33	0,1778
B	4	15	0,9222	93,33	-0,0111
B	5	15	0,9444	86,67	0,0778
B	6	15	0,9556	66,67	0,2889
C	1	15	0,8778	60,0	0,2778
C	2	15	0,9	73,33	0,1667
C	3	15	0,8333	66,67	0,1667
C	4	15	0,8778	46,67	0,4111
C	5	15	0,9111	46,67	0,4444
C	6	15	0,8	40,0	0,4




Figura 11. Brecha de calibración por ítem

Nota sobre la figura

Desglosa RQ3: ¿el desajuste entre confianza y aciertos ocurre en todo el bloque o solo en preguntas concretas (p. ej. las más difíciles)? Barras por número de pregunta (Q1 a Q6) dentro de cada condición A, B y C. Cada barra = brecha de calibración de ese ítem (misma fórmula que la Fig. 8, pero calculada solo con la confianza y el acierto de Q1, Q2, etc.). Unidad: misma brecha adimensional que la Figura 10 (–1 a +1 aprox.). Por ítem: (confianza normalizada de esa respuesta) – (1 si acertó, 0 si falló). La barra agrupa la media de los 15 participantes en ese ítem.

Compare Q1 a Q6 dentro de cada color. Picos altos (p. ej. > 0,4) = ítems donde la confianza no acompañó al acierto. Contraste con el promedio de Figura 10.

A (sin agente): peor en Q4 (brecha 0,656) B (chat texto): peor en Q6 (brecha 0,289) C (avatar y voz): peor en Q5 (brecha 0,444)

La mala calibración no es uniforme: se concentra en ítems difíciles (p. ej. A-Q4, C-Q4 a Q6). Explica por qué el promedio de C puede subir sin que «todo el avatar» des calibre por igual.




Figura 12. Curva de calibración por ítem

Nota sobre la figura

Visualiza RQ3 en forma geométrica: relación entre confianza media y acierto ítem a ítem. Ideal para ver sobreconfianza como «puntos arriba de la diagonal perfecta». Cada punto = una pregunta en una condición (A gris, B azul, C morado). Hay hasta 18 puntos (6 ítems $\times$ 3 condiciones). Eje X: confianza media normalizada (0 a 1), calculada como en RQ3. Eje Y: % de aciertos en ese ítem (0 a 100 %; 0 % = nadie acertó, 100 % = todos). Diagonal punteada: calibración perfecta ($Y/100 \approx X$). Origen de datos: promedio grupal por ítem (Tabla 3b), no una sola persona.

Puntos sobre la diagonal $\rightarrow$ más confianza que aciertos. Bajo la diagonal $\rightarrow$ más aciertos que confianza declarada. Distancia vertical a la diagonal $\approx$ magnitud del desajuste en ese ítem.

En ítems difíciles de C (Q4 a Q6), varios puntos quedan arriba de la diagonal: confianza media alta (eje X) pero % de aciertos bajo (eje Y). Ej.: C-Q6 $\approx$ 40 % aciertos con confianza normalizada $\sim 0,80 \rightarrow$ sobreconfianza visible.

Refuerza visualmente H3 (débil): en C hay ítems con alta confianza y bajo acierto. Leer junto a Figura 10 y Figura 11.

Evaluación de hipótesis H1, H2 y H3

Las hipótesis del Entregable 2 se contrastan con las medias del subconjunto completo y con la inferencia del anexo.

Contraste entre lo esperado y lo observado (subconjunto completo A+B+C):

H1 (precisión): se planteó $C \approx B > A$: el agente mejora aciertos; B y C parecidos (mismo modelo de lenguaje). En los datos, Orden observado: B (chat texto) (81,1 %) > A (sin agente) (68,9 %) > C (avatar y voz) (55,6 %). Estado: No confirmada.

H2 (confianza): se planteó $C > B > A$: más seguridad con agente y aún más con avatar. En los datos, Orden observado: A (sin agente) (6,52) > B (chat texto) (6,50) > C (avatar y voz) (6,20) (escala 1 a 7). Estado: No confirmada.

H3 (calibración): se planteó Mayor brecha en C: más desajuste entre confianza y aciertos cuando el agente es visible. En los datos, Brechas $A = 0,232$, $B = 0,106$, $C = 0,311$. Estado: Apoyo débil.

Ninguna hipótesis quedó plenamente confirmada. Lo más estable es $B > C$ en precisión con el mismo modelo de lenguaje; H3 merece seguimiento por ítem, aunque Friedman en RQ3 no fue significativo.

H1: con estos datos el orden esperado no se observa de forma clara.

H2 no se cumple: el avatar ($C = 6,20$) no dio más confianza que el chat de texto ($B = 6,50$) ni que la condición sin agente ($A = 6,52$); de hecho, C fue la más baja.

H3 tiene apoyo solo descriptivo: la brecha más alta fue en C (0,311), por encima de A (0,232) y B (0,106), pero la prueba estadística no fue significativa (Friedman $p \approx 0,21$), así que no puede darse por confirmada.

Con quince participantes estas lecturas son orientativas; conviene cruzarlas con Friedman, Wilcoxon y las tablas individuales.

6. Cuestionarios (RAW-TLX / meCUE) y tiempo

Los formularios de Google complementan RQ2: RAW-TLX en los tres bloques y meCUE en B y C.

RAW-TLX, A (sin agente): media 4,322 (n=15).

RAW-TLX, B (chat texto): media 4,289 (n=15).

RAW-TLX, C (avatar y voz): media 4,267 (n=15).

meCUE, medias grupales B vs C:

Utilidad y usabilidad (Mód. I): B=5,6, C=5,989.

Emociones (Mód. III): B=4,622, C=4,811.

Consecuencias (Mód. IV): B=4,767, C=5,1.

Evaluación global (Mód. V): B=3,133, C=3,267.

Tabla 4. RAW-TLX por condición

Condición	Media	N
A	4,322	15
B	4,289	15
C	4,267	15

Fuente: formulario Google Forms post-bloque. **Fórmula:** RAW-TLX = promedio de 6 subescalas TLX (mental, física, temporal, desempeño, esfuerzo, frustración), cada una 1 a 7.

Tabla: media grupal. **Por qué:** carga percibida tras el bloque (complemento RQ2).

RAW-TLX por participante

P##	A	B	C
P01	4,50	5,33	4,83
P02	5,33	6,00	5,00
P03	5,00	4,67	4,00
P04	4,67	5,83	5,00
P05	5,50	3,67	5,00
P06	5,67	2,00	4,67
P08	2,67	2,50	2,33
P10	1,00	4,00	2,50
P11	4,33	3,83	5,00
P12	5,17	6,00	4,00
P13	6,33	6,17	6,00
P14	4,33	3,00	3,33
P15	1,67	2,17	2,83
P16	4,83	4,83	5,67
P17	3,83	4,33	3,83




Figura 7. Carga de trabajo (RAW-TLX) por condición

Nota sobre la figura

Complementa RQ2 desde Google Forms: ¿el bloque se sintió mentalmente exigente? Ayuda a ver si C (avatar + voz) añadió carga respecto a B o A. Tres barras con la carga de trabajo percibida media al terminar cada bloque de seis ítems (formulario RAW-TLX en Google Forms). Escala: 1 a 7 (RAW-TLX = promedio simple de seis subescalas del TLX: demanda mental, física, temporal, desempeño, esfuerzo, frustración). 1 = poco exigente; 7 = muy exigente. Cálculo: una puntuación por bloque y participante; la barra es la media grupal (N = 15).

Barras más altas = más esfuerzo mental reportado al cerrar el bloque. No mide aciertos ni confianza ítem a ítem (Figura 6).

Medias grupales: A (sin agente): 4,32; B (chat texto): 4,29; C (avatar y voz): 4,27. Las tres condiciones quedaron muy parecidas (~4,3/7).. Un valor ~4 indica carga moderada (centro de la escala), no extremos.

Si C fuera mucho más agotador, podría explicar peor rendimiento en RQ1; aquí no hubo diferencias claras. La menor confianza en C no parece deberse solo a «cansancio reportado». Cruce con tiempo (Figura 9).

Tabla 5. meCUE: medias B vs C

Módulo	Media B	N B	Media C	N C
Utilidad y usabilidad (Mód. I)	5,6	15	5,989	15
Emociones (Mód. III)	4,622	15	4,811	15
Consecuencias (Mód. IV)	4,767	15	5,1	15
Evaluación global (Mód. V)	3,133	15	3,267	15

Fuente: cuestionario meCUE 2.0 en Google Forms. **Fórmula:** media de ítems Likert 1 a 7 por módulo (I, III, IV, V) y participante; tabla = media grupal en B y C. **Por qué:** experiencia declarada del agente (RQ2).

meCUE por participante (B vs C)

P##	Módulo	B	C
P01	MECUE_I	6,50	6,83
P02	MECUE_I	5,83	6,00
P03	MECUE_I	6,67	7,00
P04	MECUE_I	6,83	7,00
P05	MECUE_I	4,33	4,50
P06	MECUE_I	6,33	7,00
P08	MECUE_I	5,33	5,50
P10	MECUE_I	4,00	4,67
P11	MECUE_I	5,67	5,67
P12	MECUE_I	5,83	6,00
P13	MECUE_I	4,67	6,67

P##	Módulo	B	C
P14	MECUE_I	3,50	3,00
P15	MECUE_I	7,00	6,83
P16	MECUE_I	6,50	6,33
P17	MECUE_I	5,00	6,83
P01	MECUE_III	4,58	4,33
P02	MECUE_III	5,00	5,25
P03	MECUE_III	5,50	6,17
P04	MECUE_III	5,33	4,75
P05	MECUE_III	5,08	5,17
P06	MECUE_III	5,17	6,25
P08	MECUE_III	4,75	4,25
P10	MECUE_III	4,00	4,50
P11	MECUE_III	4,67	4,00
P12	MECUE_III	3,17	3,08
P13	MECUE_III	5,08	4,42
P14	MECUE_III	3,08	3,75
P15	MECUE_III	3,75	4,75
P16	MECUE_III	4,25	5,50
P17	MECUE_III	5,92	6,00
P01	MECUE_IV	6,50	6,00
P02	MECUE_IV	5,00	6,00
P03	MECUE_IV	7,00	5,00

P##	Módulo	B	C
P04	MECUE_IV	7,00	7,00
P05	MECUE_IV	5,50	7,00
P06	MECUE_IV	3,50	4,00
P08	MECUE_IV	4,00	4,00
P10	MECUE_IV	1,50	3,00
P11	MECUE_IV	6,00	5,00
P12	MECUE_IV	1,00	2,50
P13	MECUE_IV	7,00	7,00
P14	MECUE_IV	4,00	2,50
P15	MECUE_IV	5,50	6,50
P16	MECUE_IV	4,00	4,00
P17	MECUE_IV	4,00	7,00
P01	MECUE_V	1,00	3,00
P02	MECUE_V	4,00	4,00
P03	MECUE_V	5,00	5,00
P04	MECUE_V	5,00	5,00
P05	MECUE_V	5,00	5,00
P06	MECUE_V	5,00	5,00
P08	MECUE_V	3,00	0,00
P10	MECUE_V	-1,00	0,00
P11	MECUE_V	4,00	3,00
P12	MECUE_V	0,00	0,00

P##	Módulo	B	C
P13	MECUE_V	0,00	5,00
P14	MECUE_V	2,00	0,00
P15	MECUE_V	4,00	5,00
P16	MECUE_V	5,00	5,00
P17	MECUE_V	5,00	4,00




Figura 8. meCUE: comparación B vs C por subescala

Nota sobre la figura

Complementa RQ2 con experiencia de usuario del asistente (solo B y C; en A no hubo agente). Pregunta si el avatar se percibió más útil, agradable o globalmente mejor. Pares de barras (azul = B, morado = C) por módulo meCUE del cuestionario post-bloque en Google Forms. Escala: 1 a 7 (Likert; acuerdo con ítems del meCUE). Módulos: I utilidad, III emociones positivas/negativas, IV consecuencias anticipadas, V evaluación global (mód. II estética solo en C, no aparece en este gráfico). Cálculo: media de ítems del módulo por participante y bloque; la barra es la media grupal en B o C.

En cada par, la barra más alta = mejor percepción declarada en esa dimensión. Diferencia de 0,5 puntos ≈ medio paso en la escala Likert. No mide aciertos en Unity.

Utilidad y usabilidad (Mód. I): B=5,60, C=5,99 Emociones (Mód. III): B=4,62, C=4,81
 Consecuencias (Mód. IV): B=4,77, C=5,10 Evaluación global (Mód. V): B=3,13, C=3,27
 Estética del avatar (mód. II, solo C): 5,63

Separa percepción de desempeño: C puede gustar más y aun así rendir peor en Figura 4. Aquí las diferencias B vs C fueron modestas y no robustas tras corrección Holm. No sustituye Figuras 13 a 15.

meCUE II se aplicó solo después de C, cuando el participante ya interactuó con el avatar.

Mide estética, diseño y cercanía del personaje. No se compara con B porque el avatar animado solo existe en esa condición.

La media grupal en C fue 5,63 (n = 15). En términos generales, la presencia del personaje fue bien valorada aunque no se tradujo en más aciertos ni en mayor confianza en ese bloque.

Entre participantes el puntaje en C osciló entre 3,00 y 7,00 (rango 4,00).

Esta subescala complementa RQ2 en la dimensión de cercanía del personaje; no reemplaza la confianza ítem a ítem de Unity ni los módulos I, III y V de meCUE en B y C.

Tabla 5b. meCUE Módulo II (solo condición C)

Módulo	Media C	N
MECUE_II	5,627	15

Fuente: mismo cuestionario meCUE, módulo II (estética). **Fórmula:** media de ítems del módulo por participante en C; tabla = media grupal. **Por qué:** dimensión visual del avatar; solo aplica a condición C.

meCUE Módulo II por participante

P##	Puntuación C
P01	5,80
P02	4,80
P03	6,80
P04	7,00
P05	6,40
P06	7,00
P08	3,60
P10	3,00

P##	Puntuación C
P11	5,60
P12	4,00
P13	6,80
P14	3,40
P15	6,80
P16	6,80
P17	6,60

6.1 Tiempo de respuesta

Métrica complementaria: tiempo medio por ítem (cronómetro Unity), agregado por condición.

A (sin agente): 113,72 s (promedio de 6 ítems).

B (chat texto): 142,89 s (promedio de 6 ítems).

C (avatar y voz): 177,0 s (promedio de 6 ítems).

Tabla 6. Tiempo medio por condición

Condición	Segundos	Ítems
A	113,72	6
B	142,89	6
C	177,0	6

Fuente: cronómetro de la aplicación Unity (desde mostrar ítem hasta pulsar Entregar).

Fórmula: segundos por ítem; media de 6 ítems por participante; tabla = media grupal. **Por**

qué: eficiencia temporal (complemento RQ1).

Tiempo por ítem

Cond.	Esc.	Preg.	N	s
A	1	1	15	103,98

Cond.	Esc.	Preg.	N	s
A	1	2	15	122,9
A	1	3	15	114,8
A	1	4	15	161,32
A	1	5	15	78,93
A	1	6	15	100,41
B	2	1	15	102,93
B	2	2	15	267,22
B	2	3	15	137,86
B	2	4	15	121,06
B	2	5	15	95,71
B	2	6	15	132,53
C	3	1	15	194,69
C	3	2	15	141,44
C	3	3	15	222,29
C	3	4	15	179,61
C	3	5	15	152,84
C	3	6	15	171,1




Figura 9. Tiempo medio de respuesta por condición

Nota sobre la figura

Complementa RQ1: ¿resolver con avatar tomó más tiempo aunque no mejorara aciertos? Mide eficiencia temporal en la pantalla del ítem (no incluye duración total del chat fuera del cronómetro del ítem). Tres barras: segundos medios de resolución por condición (promedio del grupo). Unidad: segundos (s). Origen: la aplicación registra el tiempo desde que aparece la pregunta hasta pulsar Entregar. Por participante se promedian sus 6 ítems del bloque; la barra es la media de esos promedios (N = 15). Ej.: 45 s = media de ~45 s por pregunta en esa condición.

Barra más alta = más lento en la pantalla del ítem. Tiempo largo con pocos aciertos sugiere fricción; tiempo corto con muchos aciertos sugiere fluidez.

Medias grupales: A (sin agente): 114 s; B (chat texto): 143 s; C (avatar y voz): 177 s. C tomó ~63 s más por ítem que A (56 % más tiempo en promedio).

C fue la condición más lenta y la de menor precisión, coherente con costo extra (leer + escuchar + mirar avatar) sin beneficio medible en aciertos. Cruce con Figura 4.

7. Agente (B vs C)

Uso del chat según protocolo

En B y C el participante podía consultar al agente entre ítems. El protocolo pedía al menos un intercambio (mensaje + respuesta) por bloque; no obligaba a usar el chat en cada pregunta.

Ese mínimo se cumplió en el 80 % de las sesiones analizadas (12 de 15 sesiones con bloques B/C), en línea con la meta del diseño ($\geq 80\%$).

En la práctica, el chat se concentró en pocos ítems de cada bloque: $\sim 3,6$ intercambios por bloque en B y $\sim 4,4$ en C (un intercambio = un mensaje del participante y una respuesta de Gemini). Las preguntas sustantivas al agente promediaron 2,0 en B y 2,0 en C. Más conversación no implicó más aciertos en C.

El system prompt limitaba al agente a guiar sin revelar la letra correcta; no hubo filtraciones detectadas en promedio.

Comparación del agente entre B (texto) y C (avatar + voz). RQ1 a RQ3 usan los 15 participantes completos; las métricas de chat aplican a quienes tienen registro usable ($n \approx 8$ en B y 7 en C para intercambios).

HelpScore: media B=55,0 ($n=8$), media C=63,343 ($n=7$).

Engagement: media B=41,875 ($n=8$), media C=58,414 ($n=7$).

ChatExchanges: media B=3,625 ($n=8$), media C=4,429 ($n=7$).

ModelLeaks: media B=0,0 ($n=8$), media C=0,0 ($n=7$).

OnTopicSeconds: media B=135,965 ($n=8$), media C=153,437 ($n=7$).

OffTopicSeconds: media B=95,963 ($n=8$), media C=84,444 ($n=7$).

SubstantiveQuestions: media B=2,0 ($n=8$), media C=2,0 ($n=7$).

Métricas agregadas B vs C

Métrica	Media B	N B	Media C	N C
HelpScore	55,0	8	63,343	7
Engagement	41,875	8	58,414	7
ChatExchanges	3,625	8	4,429	7
ModelLeaks	0,0	8	0,0	7
OnTopicSeconds	135,965	8	153,437	7
OffTopicSeconds	95,963	8	84,444	7

Métrica	Media B	N B	Media C	N C
SubstantiveQuestions	2,0	8	2,0	7

Fuente: logs de conversación con el agente en condiciones B y C. **Agregación:** media por participante con chat usable (n variable por métrica). Definiciones completas en **Anexo A** (HelpScore, intercambios, leaks).




Figura 13. HelpScore B vs C

Nota sobre la figura

Evalúa la calidad pedagógica del chat (B vs C): ¿el agente orientó sin revelar la respuesta? No es acierto en el simulador (RQ1), sino cumplimiento del rol de tutor. Dos barras (B y C) con el HelpScore medio del grupo en cada condición. Escala: 0 a 100 (adimensional). Por intercambio: la aplicación aplica reglas heurísticas a cada par mensaje-estudiante + respuesta-Gemini (orientación, relevancia, ausencia de leak, etc.). Por bloque: HelpScore medio = promedio de los intercambios de las 6 preguntas del bloque B o C. Barra: media de esos promedios individuales (solo participantes con log de chat).

0 ≈ ayuda nula o filtración; 100 ≈ tutor ideal según el protocolo. Diferencias < 10 puntos suelen ser modestas. No es juicio humano, es scoring automático.

HelpScore medio: B = 55,0/100 (n = 8), C = 63,3/100 (n = 7). Valores intermedios-altos (~55 a 63): el agente orientó sin filtrar la respuesta en la mayoría de sesiones con chat registrado. B y C son parecidos → mismo modelo de lenguaje.

Si B y C son parecidos, la peor precisión en C (Figura 4) no se explica por peor contenido del agente, sino por modalidad, ítems o forma de usar el chat.




Figura 14. Intercambios de chat B vs C

Nota sobre la figura

Mide cuánto usaron el agente en B vs C: ¿el avatar invitó a más conversación que el chat solo texto?. Dos barras: número medio de intercambios de chat por bloque (condición B o C), promediado entre participantes con registro de chat. Unidad: conteo (número entero; la media puede ser decimal, p. ej. 3,6). 1 intercambio = el participante envía un mensaje y Gemini responde una vez. Total del bloque: se suman los intercambios de las 6 preguntas del escenario B o C. Barra: media de intercambios por participante (no es «por pregunta»).

Un bloque con 3,6 de media $\approx$ tres o cuatro idas y vuelta en total en ~ 6 ítems ($\approx 0,6$ intercambios por pregunta si se repartieran uniforme). Más intercambios $\neq$ mejor ayuda ni más aciertos automáticamente.

Intercambios medios por bloque completo (6 preguntas): B = 3,6, C = 4,4 ($n = 8$ en B, $n = 7$ en C). Qué significa 3,6: en promedio, quienes usaron chat en B enviaron ~ 3 a 4 mensajes al agente en todo el bloque (no por cada pregunta), y recibieron la misma cantidad de respuestas, 1 intercambio = 1 mensaje suyo + 1 respuesta del agente. En C la media fue $\sim 4,4$ intercambios por bloque ($\sim 0,8$ más que B). El protocolo pedía al menos 1 mensaje por bloque; muchos concentraron el chat en pocas preguntas del bloque.

En C hubo más chat por bloque pero menos aciertos (Figura 4): hablar más con el mismo modelo de lenguaje no compensó la menor precisión. Cruce con tiempo (Figura 9) y leaks (Figura 15).



Figura 15. Leaks del modelo B vs C

Nota sobre la figura

Validez del experimento: si el agente revelara la respuesta correcta, la Figura 4 mediría memoria de la pista, no aprendizaje con tutor. Esta figura verifica que el system prompt se respetó (meta del diseño: ~0 leaks por cada 10 participantes). Dos barras (B y C) con el número medio de leaks por participante y bloque. Unidad: conteo (0, 1, 2...). 1 leak = una respuesta del modelo flagged como filtración (letra A/B/C/D explícita o pista tan directa que anula el ejercicio). Por bloque: conteo de leaks en el bloque completo. Barra: media entre participantes con chat en esa condición.

Idealmente 0,0 en ambas barras. Un valor de 0,2 sería ~2 leaks cada 10 personas en promedio. Cualquier leak > 0 en una sesión compromete la validez de esa sesión.

Leaks por participante (media): B = 0,00, C = 0,00 (n = 8 / 7). Qué significa 0,00: ningún participante recibió una respuesta clasificada como leak en ese bloque; el contador es entero por persona (0, 1, 2...) y la barra es el promedio (0,0 = cero leaks en todas las sesiones analizadas). Detección automática: patrones como «la opción correcta es B» o afirmaciones que confirman la letra elegida.

Con 0 leaks, las diferencias de aciertos entre B y C se pueden atribuir a modalidad, ítems y uso del chat, no a trampa del agente. No explica por qué C rindió peor (Figura 4); descarta una amenaza interna grave. Complemento: Figura 13 (calidad) e Figura 14 (cantidad de uso).

8. Viabilidad técnica

Criterios de viabilidad del estudio (Entregable 2):

Integridad CSV válida: 100,0% (cumple meta 95%).

Latencia Gemini ≤ 5 s en $\geq 90\%$ turnos: cumple.

TTS condición C $\geq 85\%$ éxito: cumple.

Filtraciones modelo (leaks): 0 (0,0 por cada 10 participantes).

Esta sección resume si el registro automático y los servicios externos funcionaron lo bastante bien como para confiar en los datos.

Integridad CSV (100,0 % de filas válidas): proporción de respuestas guardadas sin errores de formato. Meta del estudio: $\geq 95\%$.

Latencia Gemini: tiempo de respuesta del chat. Meta: al menos 90 % de turnos ≤ 5 s. Se cumplió en el estudio.

TTS (condición C): porcentaje de síntesis de voz exitosa. Meta: $\geq 85\%$. Se cumplió.

Filtraciones del modelo (0 en total): respuestas del agente que pudieron revelar la opción correcta. Menos es mejor; influye en la validez interna.

Resumen de viabilidad

Métrica	Valor
ValidRows	270
TotalRows	270
ValidPct	100,0
Passes95PctRule	1
GeminiPasses90Pct	1
TtsPasses85Pct	1
TotalModelLeaks	0
LeaksPer10Participants	0,0
LeaksPassRule	1
AgentSessions	15

Métrica	Valor
SessionsWithChat	12
SessionsMeetingChatProtocol	12
PctSessionsWithChat	80,0
PctSessionsMeetingChatProtocol	80,0
WastedDominantSessions	1
ChatProtocolPassRule	1

Tabla V. Semáforo de viabilidad

Criterio	Meta del diseño	Valor observado	Estado
Complejidad A+B+C	≥ 80 % de participantes canónicos	100,0 % (15/15)	Cumple
Integridad CSV	≥ 95 % filas válidas	100,0 %	Cumple
Latencia Gemini	≤ 5 s en ≥ 90 % turnos	93,9 % turnos ≤ 5 s	Cumple
TTS condición C	≥ 85 % síntesis exitosas	100,0 % síntesis exitosas	Cumple
Leaks del modelo	≤ 2 por cada 10 participantes	0 total (0,0 / 10 p.)	Cumple

9. Limitaciones del diseño

Limitaciones del diseño y de la muestra.

Muestra de conveniencia (N = 15). Cada bloque usó ítems distintos (véase la salvedad al inicio de la sección 3); el contraste B vs C sigue siendo el más útil porque comparte el mismo modelo de lenguaje.

El diseño intrasujeto puede arrastrar orden o fatiga (Figura 3); el orden de bloques se contrabalanceó.

La escala de confianza 1 a 7 quedó cerca del techo (~6,2 a 6,5/7), lo que reduce sensibilidad en RQ2 y RQ3.

El perfil de la muestra fue heterogéneo (edad, educación, uso de asistentes); varios participantes percibieron los ítems como muy difíciles y otros, como sencillos. Eso dificulta calibrar un único banco de preguntas sin definir antes el usuario objetivo.

El protocolo de chat era mínimo y el uso fue desigual. Las métricas de chat (Fig. 13 a 15) usan $n = 8$ (B) y $n = 7$ (C) con registro usable, no siempre los 15 participantes de RQ1. HelpScore y leaks son heurísticas automáticas.

Entorno de ejecución distinto al planeado. En entregas anteriores se previó desplegar el experimento en una máquina virtual en la nube (AWS y Azure) para que cada participante se conectara y lo usara desde ahí, en un entorno controlado. Por límites de uso y costo de esas VM en la nube, finalmente no se desplegó así: a cada participante se le envió un ejecutable (.exe) para correr el estudio localmente en su propia laptop. Eso reduce el control sobre el entorno, porque el hardware, el sistema operativo y las condiciones de cada equipo varían entre participantes, a diferencia de la VM única descrita en el protocolo. Para no pedir envíos manuales, el ejecutable se configuró para subir automáticamente cada corrida a Google Drive, en una carpeta con el nombre de cada participante; así la recolección de datos siguió centralizada y sin fricción para el participante.

Escenarios ficticios, un solo avatar y voz, y dependencia de APIs externas: los resultados sirven para iterar el prototipo, no para generalizar a cualquier dominio.

10. Respuestas a las preguntas de investigación

Aquí va cada pregunta de investigación con los promedios y las pruebas del anexo (Friedman y Wilcoxon). Con quince participantes, $p > 0,05$ no prueba equivalencia; solo indica que no hay evidencia de diferencia.

RQ1 (precisión). Medias: A = 68,9 %, B = 81,1 %, C = 55,6 %. Orden: B > A > C.

Respuesta: sí hay diferencias (Friedman $p \approx 0,005$). El hallazgo que más pesa es B > C con el mismo modelo de lenguaje: B superó a C en 11 de 15 participantes; Wilcoxon $p = 0,022$; diferencia media $\approx 25,5$ pp. Diferencia B vs C: -25,5556 pp (IC 95 % [-38,8889, -13,3333]).

RQ2 (confianza). Medias en Unity (1 a 7): A = 6,52, B = 6,50, C = 6,20. Orden: A $\approx$ B > C.

Respuesta: diferencias globales (Friedman $p \approx 0,024$). Sin agente o con chat la gente se sintió más segura que con avatar (A vs C: $p = 0,033$). H2 (C > B > A) no se cumple. RAW-TLX: Carga percibida (RAW-TLX, 1 a 7): A (sin agente) = 4,32; B (chat texto) = 4,29; C (avatar y voz) = 4,27. meCUE: Medias meCUE (B vs C): utilidad y usabilidad (Mód. I): B = 5,6, C = 5,989; emociones (Mód. III): B = 4,622, C = 4,811; consecuencias (Mód. IV): B = 4,767, C = 5,1; evaluación global (Mód. V): B = 3,133, C = 3,267..

RQ3 (calibración). Brechas medias: A = 0,232, B = 0,106, C = 0,311 (positivo = más confianza que aciertos).

Respuesta: Friedman $p \approx 0,21$; sin prueba fuerte de diferencias entre condiciones. En promedio, C tuvo la brecha más alta (H3 con apoyo débil). B fue la mejor calibrada. Contraste dirigido A vs C: $\Delta = 0,0796$ (IC 95 % bootstrap [-0,0796, 0,2333]), Wilcoxon $p = 0,280$ (no significativo, $n = 15$). Las figuras por ítem muestran dónde se concentra el desajuste (p. ej. ítems difíciles en C).

Carga de trabajo (RAW-TLX, apoyo a RQ2). Para RAW-TLX, la prueba de Friedman no pudo aplicarse (muestra insuficiente o falta scipy; ver anexo).. Ningún contraste pareado (A vs B, A vs C o B vs C) alcanzó $p < 0,05$ tras corrección de Holm, lo cual es habitual con muestras tan pequeñas.

En meCUE (B vs C) ningún módulo alcanzó significación tras Holm; las medias muestran tendencias, pero el tamaño de muestra es muy reducido.

10.1 Funcional vs perceptual

Conviene separar rendimiento objetivo (aciertos, calibración, tiempo) de lo que reportaron en cuestionarios (carga, meCUE, estética del avatar).

En aciertos, B lideró (81,1 %) y C quedó último (55,6 %), aunque comparte el modelo de lenguaje con B. La confianza inmediata en C (6,20/7) fue la más baja.

C también fue el bloque más lento (~177 s por ítem frente a ~114 s en A, +56 %): más tiempo sin más aciertos.

La brecha entre confianza y aciertos fue mayor en C (0,311) que en B (0,106): quien veía el avatar tendía a sentirse seguro aunque acertaba menos.

En el plano perceptual, meCUE II (solo C) promedió 5,63/7: la presencia del personaje fue bien valorada estéticamente aunque no se tradujo en mejor rendimiento.

En suma: el avatar puede gustar visualmente sin traducirse en más aciertos. Si el producto busca aprendizaje, estos datos apuntan al chat en texto; si busca presencia, habría que aligerar C antes de desplegarlo.

10.2 Comentarios de participantes

Varios participantes dejaron comentarios al cerrar (sin identificar). Uno prefería el chat en silencio: la voz del avatar lo desconcentraba; eso cuadra con $B > C$ y con más tiempo por ítem en C.

Otro comentó que le habría gustado poder interactuar por voz con el agente, en lugar de limitarse al chat escrito y a escuchar al avatar hablar. En C solo hubo salida de voz (TTS), no entrada por micrófono; es una pista para un modo conversacional bidireccional en iteraciones futuras.

Otro intentó que el agente revelara la respuesta y no lo consiguió. Los registros muestran cero filtraciones del modelo.

Un participante más sintió el bloque C más incómodo y las preguntas «un poco más difíciles»; hay que recordar que C no usó los mismos ítems que B.

En otros comentarios, la dificultad general del material fue muy dispar: para algunos fue exigente, para otros, sencilla. Con aciertos entre 16 % y 100 % según persona, tiene sentido en una muestra que mezcla edades y escolaridad: un solo nivel de dificultad no le sirve a todos.

10.3 Implicaciones para diseño

Notas para el prototipo y para un estudio de seguimiento.

Si el objetivo es maximizar aciertos con el mismo modelo de lenguaje → priorizar chat en texto (B = 81,1 % vs C = 55,6 %).

Si se mantiene el avatar → ofrecer silenciar voz o modo solo texto del mismo modelo de lenguaje, revisar carga cognitiva (tiempo, distracción audiovisual) y retroalimentación cuando la confianza no coincide con el desempeño. Varios participantes pidieron explícitamente poder concentrarse sin escuchar al personaje; otro habría preferido hablarle al agente por voz en lugar de solo escribir, lo que apunta a probar STT además del TTS ya usado en C.

La brecha más alta en C sugiere cuidar mensajes que no refuercen una sensación de dominio infundada; combinar confianza ítem a ítem con resumen al cierre del bloque podría mejorar la calibración.

meCUE II en C fue positivo en promedio (5,63/7): la estética del avatar puede aportar valor percibido aunque no mejore la precisión; separar «gusto» de «aprendizaje» al evaluar interfaces encarnadas.

Para la siguiente iteración: ampliar N, usar los mismos ítems en A/B/C o un diseño factorial de dificultad, bajar el techo de la escala de confianza y registrar por qué ítem se usó el chat. Conviene también definir el perfil objetivo del usuario antes de fijar la dificultad del banco: en esta muestra mixta, lo «muy difícil» para unos fue «muy sencillo» para otros.

11. Discusión

La pregunta central es si mostrar el agente (C) cambia rendimiento y confianza frente a no tenerlo (A) o usar solo chat (B). En B y C el modelo fue el mismo; cambió la presentación.

B obtuvo 81,1 % de aciertos y C 55,6 % con el mismo modelo de lenguaje (diferencia ≈ 25,5 pp). En confianza, C (6,20/7) quedó por debajo de A (6,52) y B (6,50): el avatar no ayudó ni en aciertos ni en sensación de seguridad.

En C la brecha entre confianza y aciertos (0,311) fue mayor que en B (0,106): varios marcaron confianza alta pese a errar más en ese bloque. Para un tutor virtual eso importa: conviene revisar la retroalimentación cuando hay avatar.

El HelpScore promedio fue B = 55,0 y C = 63,3; mide si el agente orientó sin filtrar la respuesta. C no quedó peor que B en esa heurística.

No hubo filtraciones de respuesta correcta (0 leaks).

En comentarios post-sesión, quienes pidieron silenciar al avatar coinciden con B > C; quien habría preferido interactuar por voz (no solo escribir y escuchar) señala una modalidad distinta a la probada; quien probó «sacarle» la respuesta al agente confirma que el prompt funcionó.

La dificultad del material también fue dispar: unos lo vieron muy duro, otros, fácil. Eso cuadra con aciertos muy variables por ítem y con una muestra heterogénea en edad y escolaridad. Sin definir a quién va dirigido el sistema, es difícil fijar un nivel de preguntas que sirva a todos.

RAW-TLX y meCUE dan contexto de carga y experiencia tras cada bloque; la confianza ítem a ítem la registra Unity y es la que entra en RQ2 y RQ3.

Friedman puede salir significativa con pocos datos y los post hoc no; por eso miré tamaño de efecto, dirección de H1, H2 y H3 y tablas antes de sacar conclusiones.

Con quince personas, seis ítems por bloque y escenarios ficticios, esto responde al diseño planteado, no a otros contextos.

El 100,0 % de filas válidas en los CSV indica que el registro automático funcionó bien.

12. Conclusiones

Quince participantes cerraron los tres bloques (6 ítems cada uno) con registro Unity + Forms.

En desempeño (RQ1 / H1), las medias fueron A = 68,9 %, B = 81,1 % y C = 55,6 %. H1: con estos datos el orden esperado no se observa de forma clara. El contraste más interpretable es B vs C (misma IA): B superó a C en 25,5 puntos porcentuales en promedio.

En confianza (RQ2 / H2), las medias fueron A = 6,52, B = 6,50 y C = 6,20. H2 no se cumple: el avatar (C = 6,20) no dio más confianza que el chat de texto (B = 6,50) ni que la condición sin agente (A = 6,52); de hecho, C fue la más baja. Las tres quedaron muy cerca del tope de la escala (7), por lo que las diferencias son pequeñas.

En calibración (RQ3 / H3), la brecha fue mayor en C (0,311) que en A (0,232). H3 tiene apoyo solo descriptivo: la brecha más alta fue en C (0,311), por encima de A (0,232) y B (0,106), pero la prueba estadística no fue significativa (Friedman $p \approx 0,21$), así que no puede darse por confirmada. Contraste dirigido A vs C: $\Delta = 0,0796$ (IC 95 % bootstrap [-0,0796, 0,2333]), Wilcoxon $p = 0,280$ (no significativo, $n = 15$). En la práctica, un personaje visible puede dar sensación de dominio que no siempre coincide con los aciertos.

El HelpScore (evaluación automática del chat) fue B = 55,0 y C = 63,3. La modalidad visual/sonora pareció pesar más en la experiencia que en la puntuación heurística del texto.

En lo técnico, la integridad de los CSV fue del 100,0 %, Gemini cumplió la meta de latencia, el TTS cumplió y hubo 0 leaks en total.

El avatar visible no mejoró aciertos ni confianza respecto al chat en texto; B superó a C en precisión con el mismo modelo de lenguaje. El diseño intrasujeto fue viable con registro íntegro, aunque los ítems distintos por bloque limitan la generalización.

La dificultad percibida de los ítems no fue uniforme: varios participantes las describieron como muy exigentes y unos pocos, como sencillas. Eso refuerza que, con una muestra heterogénea en perfil, es difícil fijar un nivel de dificultad adecuado sin definir antes a quién va dirigido el tutor virtual.

Próximo paso: equilibrar ítems, subir N, probar chat sin voz en C y sistematizar la entrevista post-sesión. Si el producto prioriza aciertos, en esta muestra gana el chat en texto.

Referencias bibliográficas

- Glikson, E., & Woolley, A. W. (2020). Human trust in artificial intelligence: Review of empirical research. *Academy of Management Annals*, 14(2), 627–660.
- Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. *Human Factors*, 46(1), 50–80.
- Minge, M., & Thüring, M. (2018). The meCUE 2.0 user experience questionnaire. *Proceedings of Mensch und Computer 2018*.
- Hart, S. G., & Staveland, L. E. (1988). Development of NASA-TLX. *Advances in Psychology*, 52, 139–183.
- Zhang, Y., Liao, Q. V., & Bellamy, R. K. E. (2020). Effect of confidence and explanation on accuracy and trust calibration in AI-assisted decision making. *Proceedings of FAccT 2020*.
- Hornbæk, K. (2010). Dogmas in the assessment of usability evaluation methods. *Behaviour & Information Technology*, 29(1), 97–111.
- Nielsen, J. (1994). *Usability Engineering*. Morgan Kaufmann.

Anexo A: Métricas, fórmulas y origen de datos

Este anexo complementa las «Lecturas de la figura». Para cada métrica indica: **origen del dato, fórmula, agregación y por qué** se usa en el estudio.

A. Precisión (% aciertos), RQ1

- **Fuente:** aplicación Unity (respuesta elegida vs respuesta correcta por ítem y bloque).
- **Por ítem:** Acierto = 1 si la letra elegida coincide con la correcta, 0 si no.
- **Por participante y bloque:** Precisión = $(\sum \text{aciertos} / 6) \times 100$.
- **En tablas y figuras:** media aritmética de las precisiones individuales (N = 15 completos).
- **Por qué:** outcome objetivo del experimento; independiente de la opinión del participante.

B. Confianza (escala 1 a 7), RQ2

- **Fuente:** escala de confianza en Unity (popup tras cada respuesta).
- **Por bloque:** Confianza media = $(C_1 + C_2 + \dots + C_6) / 6$, con $C_i \in \{1, \dots, 7\}$.
- **En tablas:** media de esas medias individuales por condición.
- **Por qué:** mide sensación subjetiva de seguridad al responder (H2).

C. Brecha de calibración, RQ3

- **Normalización de confianza (Entregable 2):** $C_norm = (C - 1) / 6 \rightarrow$ rango $[0, 1]$.
- **Por bloque:** Brecha = media(C_norm por ítem) – (aciertos / 6). Equivalente a: confianza normalizada media menos proporción de aciertos.
- **Por ítem (Tabla 3b):** $Brecha_i = C_norm_{,i} - \text{acierto}_i$ (0 o 1).
- **Interpretación:** Brecha > 0 $\rightarrow$ sobreconfianza media; Brecha < 0 $\rightarrow$ subconfianza.
- **Por qué:** detecta si el participante «cree saber» más de lo que acierta (H3).

D. Tiempo de respuesta (segundos)

- **Fuente:** cronómetro Unity (desde mostrar ítem hasta pulsar Entregar).
- **Fórmula:** media de 6 ítems por participante y bloque; tabla = media grupal.
- **Por qué:** costo temporal; C más lento sin mejor precisión sugiere fricción cognitiva.

E. RAW-TLX (1 a 7), Google Forms

- **Fuente:** formulario post-bloque (A, B y C).
- **Fórmula:** RAW-TLX = $(TLX_mental + TLX_física + TLX_temporal + TLX_desempeño + TLX_esfuerzo + TLX_frustración) / 6$.
- **Tabla:** media grupal por condición.
- **Por qué:** carga de trabajo percibida; descarta que C sea «más agotador» en RAW-TLX.

F. meCUE 2.0 (1 a 7), Google Forms (B y C)

- **Fuente:** formulario meCUE tras bloques B y C.
- **Fórmula:** por módulo (I Utilidad, III Emociones, IV Consecuencias, V Global), media aritmética de ítems Likert del módulo.
- **Módulo II (estética):** solo condición C.
- **Por qué:** experiencia de usuario declarada; separa percepción de desempeño Unity.

G. HelpScore (0 a 100), chat B/C

- **Fuente:** evaluación automática de cada intercambio en la aplicación Unity.
- **Por intercambio:**
 - GuidanceScore: base 45; +25 si la respuesta del modelo incluye «?»; +15 si longitud 30 a 350 caracteres; –50 si leak detectado.
 - TaskEngagementScore: heurística sobre el mensaje del estudiante (off-topic, gaming, etc.).
 - HelpScore = $0,75 \times \text{Guidance} + 0,25 \times \text{Engagement}$ (si no hay leak); si hay leak: HelpScore = $0,4 \times \text{Guidance}$.
- **Por bloque:** media de HelpScore de todos los intercambios del bloque.
- **En figura/tabla:** media de esos promedios entre participantes con chat ($n \approx 8$ B, 7 C).
- **Por qué:** calidad pedagógica automática del tutor; no sustituye revisión manual.

H. Intercambios de chat (conteo)

- **Fuente:** registro de conversación del agente en Unity.
- **Definición:** 1 intercambio = 1 mensaje del participante + 1 respuesta de Gemini.
- **Agregación:** suma por bloque de 6 ítems; tabla = media entre participantes.
- **Por qué:** intensidad de uso del agente (no implica mejor aprendizaje).

I. Leaks del modelo (conteo)

- **Fuente:** registro automático de filtraciones en las respuestas del agente.
- **Definición:** +1 si la respuesta del modelo coincide con patrones de filtración (p. ej. «la opción correcta es B») o afirmación que confirma la letra elegida.
- **Agregación:** conteo por bloque; tabla = media por participante.
- **Por qué:** validez interna, si hay leaks, la precisión mide memoria de pistas.

J. Descriptivos (Media, Mediana, DE, Mín., Máx.)

- **Fuente:** agregación de las métricas anteriores por condición.
- **Media:** $\Sigma x / n$. **Mediana:** valor central ordenado. **DE:** desviación estándar muestral $\sqrt{(\Sigma(x-\bar{x})^2)/(n-1)}$.
- **Por qué:** resumen de dispersión; con $N = 15$ la mediana complementa la media.

K. Prueba de Friedman (omnibus, 3 condiciones)

- **Cuándo:** comparar A, B y C en la **misma persona** (intrasujeto).
- **Entrada:** matriz $n \times 3$ (un valor por participante y condición).
- **Estadístico:** χ^2 de Friedman.
- **Kendall W:** $W = \chi^2 / (n \times (k-1))$, $k = 3$; acuerdo de ranking entre condiciones (0 a 1).
- **Por qué no ANOVA repetida:** n pequeño, escala ordinal en confianza, robustez a no normalidad.

L. Wilcoxon pareado (post hoc)

- **Cuándo:** tras Friedman significativo (o exploratorio), pares A vs B, A vs C, B vs C.
- **Estadístico:** W de Wilcoxon pareado.
- **Corrección Bonferroni:** $p_{adj} = \min(1, 3 \times p)$. **Corrección Holm:** step-down menos conservador.
- **Por qué:** contrastes pareados sin asumir normalidad de diferencias.

M. IC bootstrap 95 % (B – C precisión)

- **Fórmula:** diferencias $d_i = \text{Precisión}_{C,i} - \text{Precisión}_{B,i}$; remuestreo con reemplazo 5000 iteraciones; IC = percentiles 2,5 y 97,5 del bootstrap.
- **Reporte:** Δ media = $\text{mean}(d)$; unidades = puntos porcentuales.
- **Por qué:** intervalo de la diferencia pareada sin supuestos paramétricos fuertes.

N. Contraste HelpScore (Wilcoxon B vs C)

- **Entrada:** pares HelpScore_B y HelpScore_C del mismo participante.
- **Por qué:** mismo modelo de lenguaje; evalúa si la modalidad cambió la calidad pedagógica heurística.

O. Criterios de viabilidad (Tabla V)

- **Integridad de datos:** proporción de respuestas válidas registradas (meta $\geq 95\%$).
- **Gemini:** % turnos con latencia ≤ 5 s (meta $\geq 90\%$). **TTS:** éxitos / intentos en C (meta $\geq 85\%$).
- **Leaks:** conteo total de filtraciones (meta ≈ 0 por cada 10 participantes).

Anexo B: Inferencia estadística

Las tablas siguientes recogen los resultados de las pruebas inferenciales del estudio. Las definiciones de pruebas (Friedman, Wilcoxon, Holm, bootstrap) están en el **Anexo A**, secciones K–M. $\alpha = 0,05$; Holm es el criterio principal para post hoc.

Pruebas omnibus (Friedman)

Análisis	Métrica	Etiqueta	Prueba	Estadístico	p	Kendall W	N
RQ1	accuracy	Precision	Friedman	10,705882	0,004734	0,356863	15
RQ2	mean_confidence	Confianza Unity	Friedman	7,470588	0,023866	0,24902	15
RQ3	Brecha de calibración	Brecha calibración	Friedman	3,137931	0,208261	0,104598	15
RQ2_FORMS	RAW_TLX	RAW-TLX	Friedman	0,655172	0,720661	0,021839	15

Post hoc pareado (Wilcoxon)

Análisis	Contraste	vs	W	p	p adj. Bonf.	p adj. Holm
RQ1	A	B	21,0	0,153438	0,460314	0,261408
RQ1	A	C	24,0	0,130704	0,392111	0,261408
RQ1	B	C	5,0	0,007417	0,022252	0,022252
RQ2	A	B	14,0	1,0	1,0	1,0
RQ2	A	C	0,0	0,010909	0,032728	0,032728
RQ2	B	C	8,0	0,085831	0,257493	0,171662
RQ3	A	B	27,5	0,115651	0,346954	0,231302
RQ3	A	C	41,0	0,279851	0,839554	0,279851
RQ3	B	C	21,0	0,04788	0,143639	0,143639

Análisis	Contraste	vs	W	p	p Bonf. adj.	p Holm adj.
RQ2_FORMS	A	B	48,5	0,801637	1,0	1,0
RQ2_FORMS	A	C	46,0	0,682201	1,0	1,0
RQ2_FORMS	B	C	56,0	0,820209	1,0	1,0

IC bootstrap 95 % (diferencia pareada)

Análisis	Contraste	vs	Δ media	IC inf.	IC sup.	Unidades
RQ1	A	B	12,2222	-0,0	24,4444	pp
RQ1	A	C	-13,3333	-27,7778	1,1111	pp
RQ1	B	C	-25,5556	-38,8889	-13,3333	pp
RQ2	A	B	-0,0222	-0,2	0,1222	units
RQ2	A	C	-0,3222	-0,5889	-0,1222	units
RQ2	B	C	-0,3	-0,6444	0,0111	units
RQ3	A	B	-0,1259	-0,2481	-0,0019	units
RQ3	A	C	0,0796	-0,0796	0,2333	units
RQ3	B	C	0,2056	0,0593	0,3593	units
RQ2_FORMS	A	B	-0,0333	-0,8113	0,6775	units
RQ2_FORMS	A	C	-0,0556	-0,4555	0,3553	units
RQ2_FORMS	B	C	-0,0223	-0,5889	0,5889	units

Contrastes dirigidos (H3, B vs C, HelpScore)

ID	Descripción	Δ	IC inf.	IC sup.	p	N
H1_B_vs_A	H1: precision B vs A (agente vs sin agente)	12,2222	-0,0	24,4444	0,153438	15

ID	Descripción	Δ	IC inf.	IC sup.	p	N
H1_C_vs_A	H1: precision C vs A (avatar vs sin agente)	-13,3333	-27,7778	1,1111	0,130704	15
VIS_B_vs_C	Contraste clave: precision B vs C (misma ayuda del modelo de lenguaje)	-25,5556	-38,8889	-13,3333	0,007417	15
H2_B_vs_A	H2: confianza Unity B vs A	-0,0222	-0,2	0,1222	1,0	15
H2_C_vs_A	H2: confianza Unity C vs A	-0,3222	-0,5889	-0,1222	0,010909	15
H2_C_vs_B	H2: confianza Unity C vs B	-0,3	-0,6444	0,0111	0,085831	15
H3_C_vs_A	H3: brecha de calibración mayor en C que en A	0,0796	-0,0796	0,2333	0,279851	15
H3_C_vs_B	H3 exploratorio: brecha C vs B	0,2056	0,0593	0,3593	0,04788	15

[RQ1]

Inferencia:

Precisión | Friedman $\chi^2=10,7059$, $p=0,0047$ ($n=15$)

Kendall $W = 0,357$ (0 = sin acuerdo, 1 = ranking idéntico entre condiciones)

Post hoc Wilcoxon pareado (Bonferroni y Holm, 3 comparaciones):

A vs B: $W=15,0000$, $p=0,0573$, $p_{\text{adj_Bonf}}=0,1719$, $p_{\text{adj_Holm}}=0,1146$

A vs C: $W=24,0000$, $p=0,1311$, $p_{\text{adj_Bonf}}=0,3932$, $p_{\text{adj_Holm}}=0,1311$

B vs C: $W=2,0000$, $p=0,0036$, $p_{\text{adj_Bonf}}=0,0109$, $p_{\text{adj_Holm}}=0,0109$ *

[RQ2 Unity]

Inferencia:

Confianza Unity | Friedman $\chi^2=7,4706$, $p=0,0239$ ($n=15$)

Kendall $W = 0,249$ (0 = sin acuerdo, 1 = ranking idéntico entre condiciones)

Post hoc Wilcoxon pareado (Bonferroni y Holm, 3 comparaciones):

A vs B: $W=14,0000$, $p=1,0000$, $p_{\text{adj_Bonf}}=1,0000$, $p_{\text{adj_Holm}}=1,0000$

A vs C: $W=0,0000$, $p=0,0109$, $p_{\text{adj_Bonf}}=0,0327$, $p_{\text{adj_Holm}}=0,0327$ *

B vs C: $W=8,0000$, $p=0,0858$, $p_{\text{adj_Bonf}}=0,2575$, $p_{\text{adj_Holm}}=0,1717$

[RQ2 Forms RAW-TLX]

Inferencia:

RAW-TLX | Friedman $\chi^2=0,6552$, $p=0,7207$ ($n=15$)

Kendall $W = 0,022$ (0 = sin acuerdo, 1 = ranking idéntico entre condiciones)

Post hoc Wilcoxon pareado (Bonferroni y Holm, 3 comparaciones):

A vs B: $W=48,5000$, $p=0,8016$, $p_{\text{adj_Bonf}}=1,0000$, $p_{\text{adj_Holm}}=1,0000$

A vs C: $W=46,0000$, $p=0,6822$, $p_{\text{adj_Bonf}}=1,0000$, $p_{\text{adj_Holm}}=1,0000$

B vs C: $W=56,0000$, $p=0,8202$, $p_{\text{adj_Bonf}}=1,0000$, $p_{\text{adj_Holm}}=1,0000$

[RQ2 Forms meCUE B vs C]

Wilcoxon pareado B vs C por módulo meCUE (p ajustada Bonferroni, 4 comparaciones):

Utilidad (Mód. I) | Wilcoxon B vs C: $W=18,0000$, $p=0,0280$, $p_{\text{adj_Holm}}=0,1120$

Emociones (Mód. III) | Wilcoxon B vs C: $W=41,5000$, $p=0,2927$, $p_{\text{adj_Holm}}=0,8781$

Consecuencias (Mód. IV) | Wilcoxon B vs C: $W=23,0000$, $p=0,3704$, $p_{\text{adj_Holm}}=0,8781$

Evaluación global (Mód. V) | Wilcoxon B vs C: $W=17,5000$, $p=0,9434$, $p_{\text{adj_Holm}}=0,9434$

[RQ3]

Inferencia:

Brecha calibración | Friedman $\chi^2=3,1379$, $p=0,2083$ ($n=15$)

Kendall W = 0,105 (0 = sin acuerdo, 1 = ranking idéntico entre condiciones)

Post hoc Wilcoxon pareado (Bonferroni y Holm, 3 comparaciones):

A vs B: $W=26,5000$, $p=0,1017$, $p_adj_Bonf=0,3051$, $p_adj_Holm=0,2034$

A vs C: $W=41,0000$, $p=0,2804$, $p_adj_Bonf=0,8413$, $p_adj_Holm=0,2804$

B vs C: $W=20,5000$, $p=0,0445$, $p_adj_Bonf=0,1335$, $p_adj_Holm=0,1335$

[Hipótesis]

=== Hipotesis exploratorias (medias grupales) ===

H1 (precision $C \sim B > A$): $A=68,9\%$ | $B=81,1\%$ | $C=55,6\%$

Orden observado (mayor a menor): $B > A > C$

H2 (confianza $C > B > A$): $A=6,52$ | $B=6,50$ | $C=6,20$

Orden observado (mayor a menor): $A > B > C$

H3 (mayor brecha en C): $A=0,231$ | $B=0,106$ | $C=0,311$

Orden observado (mayor brecha primero): $C > A > B$

Brecha C vs A: consistente con H3

[Agente HelpScore B vs C]

Wilcoxon HelpScore: requiere ≥ 3 participantes emparejados y scipy.

Nota de uso de herramientas de IA

Durante la elaboración de este documento se utilizaron herramientas de inteligencia artificial generativa, específicamente ChatGPT (OpenAI) y Claude (Anthropic), como apoyo en tareas de organización de ideas, revisión de redacción y reformulación de párrafos. Todo el contenido, los argumentos, las decisiones de diseño y la selección de fuentes son de autoría propia. Las herramientas se usaron como asistentes de escritura, no como generadores de contenido académico.